

西南交通大学



毕业设计（论文）中期检查报告

题 目：_____

西南交通大学教务处制表

此部分由学生填写			
题目名称			
题目来源	☒ 教师自拟 ☐ 生产实际 ☐ 科研课题 ☐ 学生自拟 ☐ 其他		
题目类型	毕业设计 (☐ 工程设计 ☐ 软件设计 ☐ 产品设计 ☐ 其他) 毕业论文 (☐ 理论研究 ☒ 应用研究 ☐ 其他)		
是否进驻实验室		☐ 是 ☒ 否	
实验室名称			实验室地点
资料情况	选题是否有变化 ☐ 是 ☒ 否		设计任务书 ☒ 有 ☐ 无
	指导纪要是否按进度填写 ☒ 是 ☐ 否		外文翻译 ☒ 完成 ☐ 未完成
一、毕业设计（论文）概述 多目标跟踪（Multi-Object Tracking, MOT）技术一直以来都是计算机视觉领域的一项重要研究课题。目前，MOT 算法共有两个基本范式，分别是依据检测进行跟踪（Tracking-By-Detection, TBD）和检测与跟踪联合（Joint Detection and Tracking, JDT）。TBD 范式主要依靠设计先进的数据关联方法来提升算法的跟踪效果，对于检测器则主要是直接使用已有的各种目标检测模型。TBD 属于二阶段方法，无法实现模型的端到端联合训练，前期训练成本较大，跟踪效果主要取决于检测器的优劣。JDT 范式则考虑同时获得目标检测框与数据关联所依靠的特征，如位移、外观特征等。相比 TBD 范式，JDT 范式下的 MOT 算法能够进行模型的端到端训练，速度也更快，但在数据关联部分并没有进行精心的设计，往往采用单一特征进行贪婪匹配，造成跟踪效果不佳。本文的目的是提出一种新的 MOT 算法，这种算法是属于 JDT 范式的，但是结合了 TBD 范式下数据关联的策略，期望实现跟踪效果和推理时间的平衡，为解决多目标跟踪任务提供一种新的思路。 本文设计的 MOT 模型基于无锚框目标检测框架 CenterNet，为了适应多目标跟踪任务下的目标时序特性，使模型能够更好的捕捉目标运动中的特征以及充分利用历史特征，设计了一种目标检测特征增强的策略（创新点 1）。考虑到数据关联时应该充分利用目标的多种特征，我们选择在工业界已经被广泛使用的 DeepSort 作为将被结合的 TBD 范式下的数据关联策略。DeepSort 关联策略中使用了目标的运动特征、空间特征和外观特征，其中运动特征由卡尔曼滤波预测得到，空间特征由交并比计算得到，外观特征则由独立训练的神经网络模型提取得到。显然，我们的目的是在模型输出目标检测框的同时，能够获得相应的外观特征。目标关联的本质可以视为二分图匹配问题，能够使用整数规划求解器进行求解。机器学习技术与组合优化算法结合（ML4CO）是目前人工智能的前沿领域，在我们的模型中，嵌入了一种叫做可微整数规划求解器的特殊网络层，构成匹配头，能够自动学习二分图匹配模型中的权值矩阵，而权值矩阵来源于模型中的外观特征提取网络 Adapter，因此最终能够在线训练得到一个类别无关的外观特征提取网络 Adapter（创新点 2）。 我们将本文提出的模型命名为 IPSLT(Integer Programming Solver Learned Tracker)。IPSLT 能够同时获得目标检测框和目标的外观特征，结合 DeepSort 策略，实现更加优秀的跟踪效果。我们在 MOT17 和 MOT20 测试集上与其他 MOT 算法进行对比，取得了具			

有竞争力的实验结果。同时在 MOT17 验证集上进行了大量的消融实验，实验结果证明了所提出方法的有效性。

最后，使用 TensorRT 在本地机上部署了 IPSLT，进行了相应的深度学习工程化研究。

二、毕业设计（论文）整体安排及进度

整体安排：

2023.12.25-2024.01.10：调研国内外多目标跟踪技术和求解器嵌入神经网络技术的研究现状，完成毕业论文的前期工作部分内容撰写

2024.01.11-2024.01.31：对基础模型 CenterNet 进行复现，参考近三年相关的多目标跟踪工作，掌握跟踪数据集制作与使用方法、学习已有目标跟踪项目中的代码执行结构

2024.02.01-2024.02.08：参考已有研究工作，完成针对 MOT 系统嵌入的可微整数规划求解器层的理论推导，在 Pytorch 框架下编写相应代码，进行测试，搭建完整的多目标跟踪模型

2024.02.17-2024.02.29：构建数据集格式转换模块，设计多种训练策略（方案 1：检测器和匹配器同时解冻训练；方案 2：先冻结匹配器训练检测器，然后冻结检测器训练匹配器），开始训练模型，并对结果进行评估分析，确定最优的训练策略

2024.03.01-2024.03.31：根据模型效果好坏，决定是否对模型结构进行调整。在不同数据集上（MOT17、MOT20 等）进行训练和测试，和近年来的各种方法进行相关指标的对比，记录相关实验结果

2024.04.01-2024.05.22：完善实验并整理实验代码和相关材料，撰写毕业论文

进度：截止 2024.03.31，如期完成进度安排。

三、毕业设计（论文）已完成的研究部分

1. 算法整体框架的理论设计与代码实现

多目标跟踪算法目前主要分为两类，一类是依据检测进行跟踪的 TBD 范式，一类是检测和跟踪联合的 JDT 范式。JDT 范式只需要一个骨干网就能完成跟踪信息和检测信息的获得，因此是目前 MOT 领域的研究主流。但是，目前大多数的 JDT 范式仍然存在如下问题：目标检测器和 re-ID 特征提取器训练时的期望矛盾导致整体模型训练效果不佳；通常只使用运动特征如位移等进行贪婪关联导致模型跟踪效果不佳；跟踪的部分目标形变大、外观模糊且尺寸小导致目标检测效果不佳。




图 1 算法模型的宏观框架

我们对 JDT 范式下的骨干网进行解耦，设计了一种双分支网络结构（如图 1），采用两阶段训练法，解决检测器和 re-ID 特征提取器训练时的期望矛盾。我们的算法命名为 IPSLT(Integer Programming Solver Learned Tracker)。




图 2 嵌入可微求解器用于训练 re-ID 特征提取器

我们从直观的几何结构出发，将相邻帧目标匹配建模为图论中的带权二分图最优匹配问题，引入可微整数规划器进行求解并通过误差反传在线训练一个 re-ID 特征提取器（如图 2）。这样做的好处是：re-ID 特征提取器的训练很快，因为“编码器-解码器”类型的主干特征提取网络已经在训练目标检测器的时完成参数学习，re-ID 特征提取器是一个针对下游任务的非常轻量的网络结构，只需进行微调学习。同时，由于我们的方法仅仅考虑相邻帧

目标匹配的几何结构，学习得到的 re-ID 特征提取器是类别无关的，只与对应的 MOT 任务有关。例如某 MOT 任务需要完成三种类别的多目标跟踪，那么我们的 re-ID 特征提取器能够同时获得这三种类别下的任意目标 re-ID 特征，无需分别训练三个不同类别的 re-ID 特征提取器。




图 3 嵌入可微求解器的 MOT 算法模型框架

我们提出的 MOT 算法模型基于 CenterNet，整体框架如图 3 所示。模型接受三个输入，分别是第 t 帧图像 $I_t \in \mathbb{R}^{H \times W \times 3}$ ，第 $t-1$ 帧图像 $I_{t-1} \in \mathbb{R}^{H \times W \times 3}$ 及其对应的热力图 $hm_{t-1} \in \mathbb{R}^{H_F \times W_F \times N_{cls}}$ ，其中 H 和 W 分别表示图像的高和宽， $H_F = H/R$ ， $W_F = W/R$ ， R 表示下采样因子， N_{cls} 表示类别数量。本文取 $R = 4$ 。算法模型整体共分为四个部分，分别是特征提取、特征融合、检测头和匹配头。




图 4 级联匹配框架

DeepSort 中的级联匹配中使用到了卡尔曼滤波预测的目标运动特征和 re-ID 特征提取器得到的目标外观特征。因此，我们在级联匹配中引入了我们的 re-ID 特征提取器 Adapter，完成目标检测的同时输出目标对应的 re-ID 特征，无需再数据关联时使用额外的特征提取器。我们的级联匹配结构如图 4 所示，Adapter 和检测头共用同一个 backbone（见图 1），能够同步输出目

标检测框和对应的 re-ID 特征。确定轨迹的预测指的是轨迹列表中所有确定状态的轨迹通过卡尔曼滤波估计的下一帧可能出现的位置，数据结构上的表现仍然是一些目标框。轨迹的 re-ID 特征不会被预测，沿用之前 re-ID 特征提取器得到的目标 re-ID 特征。




图 5 匹配关系梯度编码向量示意图

为了节约显存，提高训练速度，我们设计了一种匹配关系及梯度的编码数据格式。如图 5 所示，反映了如何获得匹配关系在相应位置处的梯度。整个向量共分为三个区域，分别是梯度区、坐标区和容量。其中坐标区长度为，以长度进行划分，分别存储第帧的目标、坐标和第帧的目标、坐标。最多存储个匹配关系，这个匹配关系对应的梯度存储在前长度的梯度区中。向量的最后一位表示向量的存储容量，根据具体的匹配关系动态更新，用于动态选择匹配关系和对应的梯度。

基于匹配关系梯度向量编码方法，我们对 $\frac{dL}{dy}$ 也能够进行同样的编码，编码示意图如下：




图 6 匹配关系损失函数梯度计算示意图

在训练时，从数据集中能够得到相邻帧目标匹配的情况，然后对其匹配关系进行编码得到真实匹配关系编码向量 GT ， GT 的梯度区全部置为 0。同时，我们的模型 IPSLT 能够得到预测的匹配关系，经过编码得到解方案的编码向量 Y 。从 GT 和 Y 中解析出匹配关系的集合，计算匹配并集、交集和补集。对于匹配并集中的每个匹配关系 R ，如果在交集中存在即代表 R 是正确的匹配关系，因此 R 下的损失函数梯度为 0。对于在匹配补集中的 R ，如果在 GT 中存在，则证明 IPSLT 没有正确预测出这个关系 R ，因此损失函数梯度为-1；如果在 Y 中存在，则证明 GT 中并没有这个关系存在，IPSLT 进行了错误的预测，因此损失函数梯度为 1。




图 7 $CostMap_t$ 梯度计算示意图

在实际操作中，新旧解方案都是用编码向量的数据结构进行运算。由图 6 中的计算流程最终得到 $\frac{dL}{dy}$ 的编码向量，再将其用于扰动权值矩阵 C_t ，最终得到扰动后的权值矩阵 C_t^* 。将 C_t^* 与图 3-10 中的相邻帧坐标信息一起送入整数规划求解器当中，得到新的解方案并对其进行编码。计算新旧解方案编码向量下的匹配补集，对于补集中的每一对匹配关系 R ，如果 R 在原始解方案中但是不在新的解方案中，则差分为 1。反之，差分为-1。将所有计算结果用空的匹配关系向量 G 来存储，得到差分编码向量 G 。最终乘以系数 $\frac{1}{\lambda}$ ，解码映射到原始的 $CostMap_t$ 上得到梯度 $\nabla CostMap_t$ 。计算流程如图 7 所示。

2. 在基准数据集 MOT17、MOT20 训练集上训练模型并在测试集上进行评估，与近年来发布在 CV 和 AI 领域顶会和顶刊的方法进行指标对比。

对比实验结果如下三表所示：

表 1 在 MOT17 数据集上的实验结果

方法	来源	年份	MOTA(%)↑	IDF1(%)↑	MT(%)↑	ML(%)↓	FP↓	FN↓	IDs↓
CenterTrack	ECCV	2020	67.8	64.7	34.6 %	24.6 %	18498	160332	<u>3039</u>
TraDes	CVPR	2021	69.1	63.9	36.4 %	21.5%	<u>20892</u>	150060	3555
GSDT	ICRA	2021	73.2	66.5	41.7%	17.5%	26397	120666	3891
PermaTrack	ICCV	2021	73.8	<u>68.9</u>	43.8%	<u>17.2%</u>	28998	115104	3699
FairMOT	IJCV	2021	73.7	72.3	43.2%	17.3%	27507	117477	3303
TrackFormer	CVPR	2022	<u>74.1</u>	68.0	47.3%	10.4%	34602	<u>108777</u>	2829
IPSLT(Ours)	--	--	77.6	66.8	<u>44.7%</u>	18.0%	25650	96546	4422

在 MOT17 数据集上,我们的方法在 MOTA、FN 指标上取得最优。MOTA 指标的值为 77.6, 相比 TrackFormer 的 74.1, 提高了 3.5 个点。FN 指标的值为 96546, 相比 TrackFormer 的 108777, 降低了 12231, 这表明本文的目标检测特征增强方式是有效的。MT 指标上取得次优, 相比 TrackFormer 的 47.3, 降低 2.6 个点。IDs 指标相比其他方法没有优势, 这主要是因为 MOT17 数据集中动态摄像视角的存在, 模型难以从视角动态变化的图像中提取同一目标的特征, 这是我们方法的一个缺陷。对于 IDF1, 相比 TrackFormer, 我们的方法降低了 1.2 个点。综上分析, 本文提出的方法在 MOT17 上与 TrackFormer 效果相当。从原理上分析, TrackFormer 是基于 Transformer 的 MOT 算法, 训练和推理时间较长, 而且相比本文的纯卷积方法, TrackFormer 由于自身结构特性和调优技巧, 部署难度更大, 实用性低。

表 2 在 MOT20 数据集上的实验结果

方法	来源	年份	MOTA(%)↑	IDF1(%)↑	MT(%)↑	ML(%)↓	FP↓	FN↓	IDs↓
LMOT	Acess	2021	59.1	61.1	25.1	23.0	13526	196673	1398
TicrossNet	ICIP	2023	60.6	59.3	41.2	16.4	46559	152984	4266
FairMOT	IJCV	2021	61.8	<u>67.3</u>	68.8	7.6	103440	88901	5243
TransTrack	arxiv	2022	64.5	59.2	49.1	13.6	28566	151377	3565
GSDT	ICRA	2021	67.1	67.5	53.1	<u>13.2</u>	31913	135409	3131
TrackFormer	CVPR	2022	<u>68.6</u>	65.7	<u>53.6</u>	14.6	<u>20348</u>	140373	<u>1532</u>
IPSLT(Ours)	--	--	70.5	66.2	50.1	13.6	27981	<u>122563</u>	2119

MOT20 针对的任务是密集行人跟踪, MOT20 与 MOT17 的不同点之一是 MOT20 中的视频均采用静态视角拍摄, 这意味着图像背景并不会会有大尺度的变化, 这一点契合了本文方法对动态视角敏感的特性, 带来更好的跟踪效果。从 IDs 的值分析, 可以明显证明上述结论的正确性。IPSLT 的 IDs 值为 2119, 排名第三, 相比次优值 1532, 增加 587, 考虑 MOT20 中行人跟踪的复杂性, 这部分增加量是可以接受的。对比 MOT17 下 IDs 的表现, 有显著提高。在 MOTA 指标上, 本文方法仍然表现最佳, 值为 70.5, 相比 TrackFormer 的 68.6, 提高 1.9 个点。在 FN 指标上, 本文方法达到次优。其

他指标表现适中。

表 3 在 MOT17 数据集上与其他使用外观特征的 JDT 方法对比

方法	来源	年份	MOTA(%)↑	IDF1(%)↑	MT(%)↑	ML(%)↓	FP↓	FN↓	IDs↓
JDE	ECCV	2020	63.0	59.5	35.7	17.3	39888	162927	6171
QDTrack	CVPR	2021	68.7	66.3	40.6	21.9	26589	146643	3378
TraDes	CVPR	2021	69.1	63.9	36.4	21.5	20892	150060	3555
FairMOT	IJCV	2021	73.7	72.3	<u>43.2</u>	17.3	27507	117477	3303
CSTrack	ICIP	2022	<u>74.9</u>	72.3	41.5	<u>17.5</u>	<u>23847</u>	<u>114303</u>	3567
IPSLT(Ours)	--	--	77.6	<u>66.8</u>	44.7	18.0	25650	96546	4422

本文提出的方法核心在于将整数规划求解器嵌入深度学习模型中在线学习得到一个 re-ID 特征提取器。结合 DeepSort 关联策略，实现对目标的跟踪。re-ID 向量实际上刻画的是目标的外观特征。基于此，本文的方法也属于基于外观特征的 JDT 范式。因此，此处将本文方法与其他使用外观特征的 JDT 方法进行对比。可以发现，本文方法相比其他基于外观特征的 JDT 方法有显著提升，在 MOTA、MT、FN 指标上均达到最优，在 IDF1 指标上达到次优，这证明了我们嵌入整数规划求解器学习 re-ID 特征的有效性。

以上所对比的各种方法基本来自于近年来 CV 和 AI 领域的顶会和顶刊，代表了 MOT 领域的最新研究结果，一定程度上保证了对比实验的可靠性。

3. 将 MOT17 训练集分为两部分，一半用于训练，一半作为验证集进行消融实验。完成了对目标检测增强、Adapter 结构设计、re-ID 特征维数选择、不同的数据关联策略等四项消融实验与分析。

表 3 目标检测特征增强策略消融实验

目标检测方法	MOTA(%)↑	IDF1(%)↑	MT(%)↑	ML(%)↓	FP(%)↓	FN(%)↓	IDs(%)↓
Baseline	70.8	71.2	47.8	13.0	2.3	26.3	0.6
w.o. DCN	67.9	59.8	41.6	13.0	3.1	28.3	0.7
w.o. previous image	70.4	71.3	43.1	16.5	1.8	27.3	0.5
w.o.previous heatmap	70.6	69.4	44.2	14.7	1.4	27.6	0.4
Ours	71.8	72.0	48.4	13.9	1.6	26.2	0.5

相比不做任何改进的 CenterNet (Baseline)，使用经过我们改进的目标检测方法，显著提高了模型的多目标跟踪任务表现效果(Ours 对比 Baseline)。只是进行简单的过去帧或热力图特征的堆叠，而不进行 DCN 变换，不能带来模型效果的改善，甚至会造成损失 (w.o. DCN 对比 Baseline、Ours)。只有同时引入过去帧图像和热力图才能带来跟踪效果的提升 (w.o. previous image、w.o.previous heatmap 对比 Baseline、Ours)。

表 4 re-ID 特征维数选择消融实验

re-ID特征维数	MOTA(%)↑	IDF1(%)↑	MT(%)↑	ML(%)↓	IDs(%)↓
128	71.6	73.1	47.2	14.5	0.5
256	71.6	73.3	46.3	14.2	0.4
512(Ours)	71.8	72.0	48.4	13.9	0.5
1024	71.6	72.5	46.6	14.5	0.5

分析表 4，我们选择 512 作为 re-ID 特征的维数。

表 5 Adapter 结构选择消融实验

Adapter结构	MOTA(%)↑	IDF1(%)↑	MT(%)↑	ML(%)↓	IDs(%)↓
MLP-based	68.5	58.5	47.8	11.2	2.3
CNN-based(Ours)	71.8	72.0	48.4	13.9	0.5

相比 MLP，CNN 能够保留输入输出特征的空间结构信息，对于目标平移、旋转、尺度变换不敏感。因此，最终得到的 re-ID 特征也比 MLP 得到的更为准确。基于此，数据关联效果也更好。

表 6 不同数据关联策略消融实验

数据关联策略	MOTA(%)↑	IDF1(%)↑	MT(%)↑	ML(%)↓	IDs(%)↓	Time(ms)
Matchhead	69.5	42.0	52.2	11.8	3.3	100
异步DeepSort	72.3	72.6	48.4	12.1	0.3	263
同步DeepSort(Ours)	72.2	70.8	48.4	12.7	0.3	127
$\Delta(\text{同步} - \text{异步})$	-0.1	-1.8	0	+0.6	0	-136




图 8 t-SNE 降维分析（左异步，右同步）

同步 DeepSort 相比异步 DeepSort 在跟踪效果上略有下降，但是推理速度提升 51.7%。t-SNE 分析显示我们的 Adapter 具备重识别能力，虽然与独有的 re-ID 特征提取器相比仍然存在不足，但是可以接受的。

4. 将 Pytorch 框架下训练模型成功转换成 ONNX 格式，使用推理引擎 TensorRT 部署在本地机实现高速推理，对比分析了部署前后的推理速度。
5. 已经撰写部分论文

四、毕业设计（论文）工作中存在的问题

未考虑更加复杂的数据关联建模方式，仅仅只考虑了相邻两帧的目标匹配。

五、下一部分的工作安排

首先完成毕业论文的撰写。若有时间，使用 TensorRT 对模型进行 FP16、INT8 量化，并进行不同量化方式下的模型推理速度对比。

学生（签名）：

____年__月__日

