

西南交通大学电气工程学院本科毕业设计(论文)开题报告

毕业设计 论文题目	面向低空协同环境理解的无人机板载视觉语言模型设计			
学生姓名	王腾越	学生学号	2022114376	
专 业	电子信息工程（人工智能技术）			
校内毕业设 计论文	校内导师 姓 名	李崇维	导师职称	讲师
校外毕业设 计论文	校外单位名称			
	校外导师姓名		导师职称	
选题类型	☐ 毕业论文(理论研究) ☒ 毕业论文(应用研究) ☐ 毕业设计(工程设计) ☐ 毕业设计(软件设计)			
资料情况	1、设计任务书		☒ 有	☐ 无
	2、外文资料翻译		☒ 完成	☐ 未完成
	3、毕业设计指导日志		☒ 填写	☐ 未填写
选题 意义 和国 内外 研究 现状 分析	一、研究背景和选题意义 随着“低空经济”概念的兴起与蓬勃发展，无人机（UAV）的应用场景正在经历一场深刻的变革，从过去以航拍、巡检等简单任务为主，迅速向多机协同、自主物流、城市安防等高度复杂的自主任务转型。在这些高阶应用中，无人机不仅需要具备基础的“看见”能力（如通过 YOLO 等算法检测和识别目标），更迫切需要拥有深层次的“理解”能力。 传统感知系统的核心局限在于“看见”与“理解”之间的鸿沟。例如，传统的局部避障方法基于激光点云，透明玻璃、镜面、细小铁丝网等障碍物由于物理特性，无法在点云中形成有效聚类。暴露了该类方法只能对单一距离信息进行处理，而不能理解环境，对一些异常环境无法做出有效判断和决策的缺陷；而在多机协同避障的复杂场景中，仅仅检测到“前方有障碍物”是远远不够的。无人机需要理解“前方障碍物正在以高速向左移动，且其轨迹将与我方预定航线在 3 秒后交汇，建议立即向右爬升”。综上，一架真正智能的无人机需要能够同时拥有对动静态环境的语义推理能力。 视觉语言模型（Vision-Language Models, VLM）的出现，为无人机视觉语言导			

航（VLN）工作提供了强大的基座模型解决方案。然而，当前主流的 VLM（如 GPT-4V）在无人机视觉语言导航应用中面临三大核心挑战：其一，现有 VLM 大多面向单个图像的处理，推理主要基于空间关系（如“猫在桌子上”）和共现关系，没有理解在无人机连续图像流中的时间方向性而造成错误的因果归因和时序定位；其二，云端推理延迟（Latency）问题，网络往返时间（RTT）对于实时交互且安全关键型的无人机任务是难以接受的，限制了无人机在通信困难的环境作业的可能；大规模数据的持续上传和云端推理的高昂运营成本限制了服务的普及。

面对上述两大挑战，本文认为在无人机上进行边缘侧流式在线推理具有绝对的必要性。无人机作业的实时性要求感知系统必须“永远在线”，将模型直接部署在边缘侧设备上，避免了不稳定的空地通信带宽和高延迟对导航避障任务的影响；而流式视频在线推理模型不同于传统视觉语言模型和离线视频理解模型（即模型在处理查询之前已经获取了完整的视频文件），视频数据以连续流的形式到达，模型在当前时刻只能基于当前时刻及其之前的历史记忆信息，对过去，现在和未来做出理解并自主决定何时进行问答反馈和决策。

综上所述，本研究的选题意义在于直面当前低空经济技术栈中的核心痛点。设计一个轻量化的、支持实时视频流输入并对输入视频流进行精确在线流式推理的视觉语言模型，不仅是技术上的巨大挑战，更是推动无人机从“工具”向“智能体”跨越的关键一步。

二、国内外研究现状

本文的目标是设计一个轻量化的、支持实时视频流输入并对输入视频流进行精确在线流式推理的视觉语言模型，基于此，本节将全面梳理视觉语言模型（VLM），模型的加速推理和高效部署，以及无人机视觉语言导航（VLN）领域的研究现状，并重点评述其在迈向真正“空中智能体”时存在的结构性缺陷，从而清晰地引出本研究的核心切入点。

1. 视觉语言模型（VLM）的发展历程

随着人工智能技术从单一模态向多模态融合的演进，视觉语言模型成为连接数字世界与物理世界的关键纽带。VLM 不仅具备了对图像和视频内容的深度语义理解能力，更继承了大语言模型（LLM）强大的逻辑推理与泛化能力，这种“感知+认知”的双重特性使其成为具身智能（Embodied AI）的核心大脑^[1]。本节调研遵循从

静态认知到动态交互、从巨量大模型到轻量小模型的技术迭代过程。

1.1 处理图像为主的开/闭源模型

VLM 的核心挑战在于如何将异构的视觉信号映射到语言模型能够理解的语义空间。OpenAI 发布的 CLIP (Contrastive Language-Image Pre-training) 模型^[2]是这一领域的里程碑工作。CLIP 利用互联网上主要抓取的 4 亿对图文数据,通过对比学习 (Contrastive Learning) 训练了一个强大的视觉编码器和文本编码器。它并不直接生成文本,而是学习将图像和文本映射到同一个高维特征空间,使得语义相似的图文在空间距离上尽可能接近。CLIP 的出现解决了“视觉特征如何被语言理解”的根本问题,为后续的生成式 VLM 提供了通用的视觉感知底座。许多后续的 SOTA 模型,包括 LLaVA 系列,都直接采用了 CLIP (如 ViT-L/14) 作为视觉前端。

CLIP 仅能实现特征匹配而无法生成连续文本,为此 LLaVA(Large Language and Vision Assistant) ^[3]引入了视觉指令微调 (Visual Instruction Tuning): 通过线性投影层将视觉 Token 馈入大语言模型 (LLM), 并采用两阶段训练策略: 首先进行特征对齐预训练,冻结视觉编码器和 LLM,仅训练投影层。其目标是利用大规模图文对,将视觉特征高效地对齐到 LLM 的词嵌入空间。随后使用由 GPT-4 等强模型生成的高质量、多样化的指令对话数据,对投影层和 LLM 进行联合微调,从而赋予模型遵循复杂指令、进行多轮对话和深入推理的能力。这一架构范式的演进也体现了领域的快速迭代: 后续版本如 LLaVA-1.5^[4]发现,采用更复杂的 MLP 投影层替代简单的线性层,能够显著提升模型在细粒度视觉理解等任务上的表现,这揭示了投影层设计成为 VLM 架构优化的一个关键环节。

在开源社区之外,以 GPT-4V 和 Google Gemini 为代表的闭源模型,凭借超大规模的数据和算力,将静态图像理解的能力推向了新的高度。GPT-4V^[5]展现了惊人的常识推理和世界知识整合能力,能够理解从复杂图表到讽刺漫画的深层含义。而 Gemini^[6]系列则更进一步,其原生多模态训练 (Native Multimodal Training) 是一项关键的技术路线差异。与后期“拼接”不同模态模块的方案相比,这种从训练之初就在多模态数据上联合进行的方式,避免了因模态融合不充分而产生的性能妥协,实现了图像、音频和视频之间更为无缝和强大的理解。特别是 Gemini 1.5 Pro 引入的 100 万 Token 上下文窗口,为其分析长视频或海量图像集提供了前所未有的潜力。然而,这些云端巨型模型虽然能力强大,但其计算模式本质上是处理离散视觉快照

的“静态”模式。因此，这些静态模型在处理连续时间信息上的根本性缺陷，为下一代技术演进创造了明确的发展方向：发展能够理解视频叙事的模型。

1.2 视频理解模型

为了将认知能力扩展至时间维度，研究人员开发了 Video-LLaVA^[7]和 VideoChat^[8]等离线视频视觉语言模型。Video-LLaVA 在统一的特征空间内整合了图像和视频表征，使 LLM 能够利用静态视觉知识进行动态场景理解；VideoChat 则引入了记忆库（Memory Bank）等机制，以增强对长视频序列的时空推理能力，专注于以对话为中心的视频理解。这种“全知视角”允许模型利用全局双向注意力机制（Bidirectional Attention）同时访问过去和未来的帧，从而轻松捕捉长距离依赖关系。虽然这类模型在回顾性分析（例如，“视频中发生了什么？”）方面行之有效，但其固有的非因果（Non-causal）处理模式——即推理开始前需获取完整视频片段，显然不适用于自动驾驶，具身智能等只能获取当前及之前历史信息的任务。

为了解决离线模型的显存爆炸和非因果性问题，赋予 AI 系统像人类一样“边看边想”的能力，在线流式推理（Online Streaming Inference）成为 VLM 发展的最新前沿。StreamingVLM^[9]发现 Transformer 的注意力机制依赖于初始的几个 Token（被称为“注意力汇点（Attention Sink）”）来保持稳定。因此，StreamingVLM 的核心策略是：在一个固定大小的滚动 KV 缓存（Rolling KV Cache）中，当新的视频帧进入时，最旧的帧信息被丢弃，但初始的“注意力汇点”Token 被永久保留。这一设计使得 StreamingVLM 能够在固定的显存占用下，高效处理无限长的视频流。

2024-2025 年研究的一个显著趋势是从“被动式”（Reactive）向“主动式”（Proactive）系统的演进。真正的智能助手（例如导盲犬机器人或实时体育解说系统）必须具备主动性，即能够自主识别视频流中的关键事件，并在合适的时机主动发起对话或解释。VideoLLM-online^[10]模型及其 LIVE 框架则进一步优化了流式交互的体验。它通过训练模型自主预测“沉默 Token”，让模型能够智能地判断何时应该输出回应、何时应该保持观察。这实现了从被动问答到主动式、事件驱动型对话（Proactive, Event-driven Dialogue）的转变，将模型从一个问答工具转变为能够主动报告其观察结果的智能代理，这对自主监控至关重要。此外，其设计的异步并行推理管道将视觉编码与 LLM 计算解耦，在 3090GPU 上最高达到了 10 FPS 的处理速度，显著提升了系统的实时性。

1.3 小参数量模型

尽管流式模型在算法层面解决了实时性问题，但在实际部署中，云端推理所固有的物理限制依然是一道难以逾越的障碍。为了克服云端推理的瓶颈，在算力和功耗都极为受限的板载设备（如 NVIDIA Jetson 系列）上部署 VLM，小参数量模型（Small VLMs）应运而生。这类模型的核心目标是在极致压缩模型规模的同时，最大限度地保留大模型的关键能力。近期的开源模型如 SmolVLM^[11]和 Qwen2.5-VL^[12]证明，较小的参数量也能实现高质量推理，使其可部署在计算受限的边缘侧设备上。虽然小模型降低了部署门槛，但要在资源极度受限的设备上实现工业级实时性，仍需深度的工程优化。下一节将重点讨论模型的推理加速与高效部署技术。

2. 模型的加速推理与高效部署

典型的 VLM 由一个庞大的视觉编码器（Visual Encoder）、一个负责模态对齐的投影层（Projector）以及一个 Decoder-only 架构的语言模型骨干网络构成。这种异构组合使其在实际应用中面临着静态存储压力和动态计算瓶颈的双重挑战。本节将分为两个核心部分进行研究现状调研。第一部分将聚焦于高效部署，详细阐述模型剪枝（Pruning）、知识蒸馏（Knowledge Distillation）和量化（Quantization）这三种旨在减少模型静态资源占用的关键技术。第二部分将转向加速推理，深入剖析针对视觉语言模型中 Decoder-only 架构的优化策略，分别探讨计算密集型的预填充（Prefill）阶段和访存密集型的自回归（Decode）阶段的加速框架方法。

2.1 模型的高效部署

2.1.1 模型剪枝

模型剪枝通过移除神经网络中非必要的权重或整个结构单元来精简模型，达到减少参数量的目的。在 VLM 的剪枝实践中，核心挑战在于如何科学地定义参数的“重要性”，因为模型中视觉 Token 与文本 Token 在激活值的分布上存在显著差异，传统的剪枝标准可能不再适用。Wanda^[13]方法引入了激活感知机制，通过权重幅度与输入激活二阶范数的乘积来衡量重要性，利用多模态校准集在不重训练的情况下实现了较高的压缩鲁棒性。然而，Wanda 的启发式准则可能引发局部重构误差，SparseGPT^[14]进一步将其建模为二阶优化问题，利用海森矩阵（Hessian Matrix）的逆来更新权重并补偿误差，从而在极高稀疏度下展现出优于 Wanda 的精度表现。剪

枝同样可以应用于模型的视觉编码器部分。**AutoPrune**^[15]方法引入一个可学习的门控机制,该机制能根据输入图像的复杂度动态判断每个 ViT 模块的必要性。在部署时,可以将这一动态决策固化,永久性地移除对模型贡献较低的 ViT 层,从而实现静态加速。

2.1.2 知识蒸馏

知识蒸馏 (Knowledge Distillation, KD) 是另一种有效的模型轻量化途径。它将一个大型、复杂的“教师”模型所学到的知识迁移到一个小型的“学生”模型中。在 VLM 领域,蒸馏的复杂度更高,因为它不仅需要传递模型的推理能力,还必须确保关键的跨模态对齐知识不丢失。早期的研究主要沿袭 Hinton 等人^[16]提出的“教师-学生”架构,利用教师模型的软标签 (Soft Targets) 作为监督信号来训练轻量级学生模型。在这一阶段,研究重点在于如何更有效地对齐教师与学生模型在输出层或中间隐藏层的分布。随着 GPT-4 等闭源模型的兴起,获取模型内部参数或 Logits 变得愈发困难,研究重心随之转向基于合成数据的黑盒蒸馏 (Data Distillation)。Wang 等人 (2022) ^[17]提出的 Self-Instruct 框架通过利用少量种子指令引导大模型生成大规模指令微调数据,证明了模型具备自我对齐的潜力。为了进一步缩小开源小模型与闭源大模型在复杂任务上的差距,近年来,学术界开始关注思维链 (Chain-of-Thought, CoT) 与推理过程的蒸馏。不同于仅关注最终答案的传统微调,CoT 蒸馏强调将教师模型的中间推理步骤作为显性监督信号。Google 的研究表明,通过学习教师的推理轨迹 (Rationales), 学生模型能够更好地泛化至未见过的数学与逻辑任务^[18]。

2.1.3 模型量化

量化通过降低模型权重和激活值的数值精度 (例如,从 16 位浮点数 FP16 转换为 8 位/4 位整数 INT8/INT4) 来压缩模型。早期的量化工作主要集中在后训练量化 (Post-Training Quantization, PTQ), 旨在无需重新训练的情况下将模型权重和激活从浮点数 (FP16/BF16) 映射到低精度整数 (INT8/INT4), 如 Frantar 等人 (2023) 提出的 GPTQ 算法^[19], Lin 等人 (2023) 提出的 AWQ 算法^[20]等。在量化与微调的融合方面,传统的量化感知训练 (QAT) 因计算成本过高而在 LLM 时代难以普及,取而代之的是参数高效的量化微调技术。Dettmers 等人 (2023) 提出的 QLoRA^[21]开创性地设计了正态浮点数 (Normal Float 4, NF4) 数据类型,这一数据类型在信息

论层面针对正态分布权重的分位点进行了最优对齐。

2.2 模型的加速推理

主流的 Decoder-only 架构的大模型的推理过程在计算特性上呈现出显著的双模态特征，即计算密集型的预填充（Prefill）阶段与显存带宽受限的解码（Decode）阶段。

针对预填充阶段，优化核心在于解决长序列下的注意力计算瓶颈与调度阻塞。Dao 等人（2022）提出的 FlashAttention 算法^[22]是 TensorRT-LLM 等高性能框架的基石，它通过分块计算与算子融合，在 SRAM 内完成注意力操作，从而打破了 HBM 与计算单元间的 I/O 瓶颈，将注意力机制的时间复杂度有效降低。

解码阶段作为自回归生成的逐 Token 过程，其主要瓶颈在于极低的算术强度，以及 KV Cache 加载带来的显存带宽压力。Yu 等人（2022）提出的 Orca 系统^[23]率先引入了迭代级调度，打破了传统静态批处理必须等待所有请求完成的限制，显著提升了 GPU 的利用率，这一机制现已成为 TensorRT-LLM 与 TGI 等主流框架的标配。在显存管理层面，Kwon 等人（2023）受操作系统虚拟内存启发提出的 PagedAttention 算法^[24]（vLLM 的核心技术），通过将连续的 KV Cache 映射到非连续的物理显存块中，彻底消除了显存碎片，使得系统能够支持更大的批处理大小（Batch Size），进而大幅提升了显存受限场景下的吞吐量。

此外，针对边缘设备或资源受限环境下的解码加速，以 llama.cpp^[25]为代表的框架探索了极致的量化与异构计算路径。不同于服务器端框架侧重于算子融合，llama.cpp 通过深度优化针对 CPU（AVX/NEON）与 Apple Silicon（Metal）的矩阵乘法内核，有效降低了模型权重与 KV Cache 的显存占用。这种方法从根本上降低了对显存带宽的需求，使得在 CPU 上进行高推理速度的大模型部署成为可能，补充了以 NVIDIA GPU 为主导的数据中心推理方案。

3. 无人机视觉语言导航（VLN）的发展

视觉语言模型（VLM）与视觉-语言-行动（VLA）模型的出现，为无人机自主导航带来了革命性的变革。这些新范式旨在赋予无人机系统类似人类的认知能力，使其能够理解复杂的自然语言指令，并基于视觉输入进行细致的环境推理与长远规划。本节主要综述了无人机视觉语言导航（VLN）领域的相关研究工作，重点从记忆机制的有无以及轻量化实时部署能力两个核心维度对现有算法进行系统性分类

与剖析。

在自主导航技术的发展初期，无记忆导航方法因其简洁高效而成为重要的研究起点。该方法的核心思想是，智能体的决策主要依据其当前时刻的传感器输入，而不维护一个持久的内部地图或对历史观测的长时程记忆。这种反应式机制构成了迈向智能自主的第一步，但其能力边界也同样清晰。在 AerialVLN^[26]任务中评估的经典 Seq2Seq 和跨模态注意力（CMA）模型，将当前的视觉观测与语言指令进行特征对齐，并直接预测离散动作序列。然而，此类模型在面对大规模城市环境时表现出明显的局限性：由于缺乏对历史信息的建模，智能体在长航程任务中极易产生路径偏移，且一旦偏离预定轨迹便无法自主纠偏或找回路径，导致导航成功率在长距离依赖场景下非常不理想（不到 20%）。为提升系统的认知能力，研究者们提出了更为先进的无记忆导航范式，其中“See, Point, Fly”（SPF）^[27]框架是杰出的代表。SPF 巧妙地利用一个冻结的视觉语言模型（VLM），将用户的自然语言指令与单帧视觉图像直接转化为一个位于图像平面内的二维航点（2D waypoint），随后将其反投影为三维空间中的位移向量以供无人机立即执行。其最大的优势在于，作为一个零样本（zero-shot）系统，它无需任何针对特定任务的训练，便能处理形式自由的指令，展现出强大的泛化能力。然而，SPF 的无记忆特性也暴露了一个根本性瓶颈：其决策周期与大型 VLM 的推理延迟（约 1-3 秒）绑定，导致其高层推理频率仅为 0.3-1 赫兹，而底层控制器则以约 10 赫兹的频率运行。这种显著的频率失配，对于需要在动态环境中进行实时反应控制的敏捷无人机而言是不可接受的。更重要的是，由于缺乏时间上下文，SPF 难以执行需要长时程规划或搜索的任务，特别是当目标在初始视场之外或被遮挡时，系统便会因缺乏历史信息而“束手无策”。

为了克服这些挑战，导航系统必须具备整合多帧信息的能力，这自然引出了对记忆机制的引入。CityNavAgent^[28]设计了全局记忆模块，将历史轨迹存储为拓扑图，有效简化了重复访问任务的规划复杂度。针对长时导航中历史信息量过大导致的计算开销问题，LongFly^[29]进一步提出了基于槽位的历史图像压缩策略，利用 GRU（Gate Recurrent Unit）实现了历史图像压缩，将碎片化的历史信息转化为紧凑的时空上下文表示。同时，SkyVLN^[30]引入了回溯记忆机制，允许智能体在面对歧义指令或探索失败时，利用历史路径进行自主纠偏。

现有方法虽然通过记忆机制提升了导航的健壮性，但由于其复杂的推理逻辑，

	往往高度依赖大算力的离线服务器，难以满足实时任务的需求；且上述方法中，低保真的记忆机制使得系统难以建立起类似人类驾驶员那样的连续、精细的视觉记忆流，进而在长程任务中容易出现空间理解的偏差。 综上，现有无人机视觉导航任务普遍存在以下三大核心痛点： （1）推理的离散化与高延迟：当前多数方法采用一种“观察-推理-行动-停止”的循环模式。这种模式导致无人机的飞行姿态不连贯，其控制响应频率（通常为 2-3Hz）比底层飞控的需求（>50Hz）低了一个数量级。这与自动驾驶所需的平滑、连续的流体控制理念背道而驰，使其无法有效应对飞行路径中突然出现的动态威胁（如飞鸟、其他无人机）。 （2）时空上下文的遗忘：大部分现有的视觉语言导航模型是无状态的或记忆机制不足，它们倾向于独立处理每一帧图像，缺乏对短时序动态变化的高保真记忆。这导致模型无法像人类驾驶员一样，在脑海中保持对动态环境的“视觉暂留”，从而在复杂的时序任务中容易丢失关键信息。 （3）动态感知与静态规划的割裂：现有工作大多假设环境是静态的，或主要处理静态目标导航。它们普遍缺乏对动态物体（如地面移动的行人、车辆）进行轨迹预测和风险评估的机制。这使得无人机在繁忙的城市低空环境中显得极其脆弱，无法进行主动的、预判性的规避。
主要研究目标和研究内容	三、研究目标 本研究旨在构建适用于无人机边缘侧的实时流式感知架构，具体目标为： 第一，将 VideoLLM-online 的流式推理机制与 Qwen2.5-VL-2B/SmolVLM-2B 等的先进多模态小参数模型进行深度融合与优化，使其适配无人机高动态、资源受限的应用场景。 第二，设计一种“基于运动显著性的时空剪枝”的核心创新算法。该算法旨在解决传统空间剪枝策略在无人机动态场景下，可能因滤除不显著但危险的运动目标而导致安全隐患的核心矛盾。 第三，提出一个基于计算受限平台的部署方案。该方案将包括详细的硬件资源预算分析、推理加速技术栈规划，以及为保证系统实时性而设计的异步处理流水线，旨在消费级 3090GPU 上达到 5-10FPS。 四、研究内容

	研究内容主要分为五个部分: 第一部分: 相关理论与技术研究。从国内外的的发展状况出发, 对视觉语言模型 (VLM), 模型的加速推理和高效部署, 以及无人机视觉语言导航 (VLN) 领域的相关工作作出文献综述, 奠定本次研究的理论基础和必要性。 第二部分: 总体框架设计。确定包括数据集生成方式, 小参数模型的选型, 微调方法的选择, 训练损失函数设计, 以及最终实验验证指标等内容。 第三部分: 创新模块设计。重点设计物理动态理解模块, Python 和 PyTorch 编程实现“基于运动显著性的时空剪枝”算法, 并将其作为一个预处理模块, 无缝集成到模型的推理流程中。 第四部分: 高效部署与实验验证。对微调后的模型进行适当量化, 研究并应用 TensorRT-LLM 等加速框架对其进行转换和加速; 从实时性 (FPS)、资源占用 (VRAM、CPU/GPU 利用率) 以及物理动态验证集理解的准确性等多个维度, 全面评估本框架的综合性能。 第五部分: 根据最终得到的实验结果进行进一步的阐述与总结, 分析本次研究中存在的不足, 并提出展望。
工作计划及进度安排	第 1-2 周: 阅读国内外文献完成文献综述与开题报告。 第 3-5 周: 复现 VideoLLM-online 的视频流式推理框架, 构建视频动态理解数据集, 考虑使用小参数多模态模型替代原有主干网络 Llama2/3。 第 6-10 周: 设计并实现运动引导剪枝算法, 重构 Streaming EOS 损失函数, 在仿真环境中完成初步模型微调。 第 11-13 周: 进行在计算受限设备上的模型部署与实验指标评估, 同步开始撰写论文。 第 14-15 周: 整理评估数据, 完成论文初稿。 第 16-17 周: 修改、定稿、准备答辩。

参考文献	参考文献不少于 10 篇（外文资料不少于 1 篇，期刊类文献不少于 5 篇） [1] Ma, Y., Song, Z., Zhuang, Y., Hao, J., & King, I. (2024). A Survey on Vision-Language-Action Models for Embodied AI. ArXiv, abs/2405.14093. [2] Radford, Alec et al. "Learning Transferable Visual Models From Natural Language Supervision." International Conference on Machine Learning (2021). [3] Liu, H., Li, C., Wu, Q., & Lee, Y.J. (2023). Visual Instruction Tuning. ArXiv, abs/2304.08485. [4] Liu, Haotian et al. "Improved Baselines with Visual Instruction Tuning." 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (2023): 26286-26296. [5] Achiam, OpenAI Josh et al. "GPT-4 Technical Report." (2023). [6] Gemini Team, "Gemini: A Family of Highly Capable Multimodal Models," arXiv preprint arXiv:2312.11805, 2023. [7] Lin, B., Zhu, B., Ye, Y., Ning, M., Jin, P., & Yuan, L. (2023). Video-LLaVA: Learning United Visual Representation by Alignment Before Projection. ArXiv, abs/2311.10122. [8] Li, K., He, Y., Wang, Y., Li, Y., Wang, W., Luo, P., Wang, Y., Wang, L., & Qiao, Y. (2023). VideoChat: chat-centric video understanding. Science China Information Sciences, 68. [9] Xu, R., Xiao, G., Chen, Y., He, L., Peng, K., Lu, Y., & Han, S. (2025). StreamingVLM: Real-Time Understanding for Infinite Video Streams. ArXiv, abs/2510.09608. [10] J. He et al., "VideoLLM-online: Online Video Large Language Model for Streaming Video," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2024. [11] A. Marafioti et al., "SmolVLM: Redefining Small and Efficient Multimodal Models," arXiv preprint arXiv:2504.05299, 2025. [12] S. Bai et al., "Qwen2.5-VL Technical Report," arXiv preprint arXiv:2502.13923, 2025. [13] M. Sun et al., "A Simple and Effective Pruning Approach for Large Language
------	--

	Models," in Proc. Int. Conf. Learn. Represent. (ICLR), 2024.
	[14] E. Frantar and D. Alistarh, "SparseGPT: Massive Language Models Can Be Accurately Pruned in One-Shot," in Proc. Int. Conf. Mach. Learn. (ICML), 2023, pp. 10323–10337.
	[15] Wang, H., Xu, Y., Xu, Z., Gao, J., Liu, Y., Hu, W., Wang, K., & Zhang, Z. (2025). AutoPrune: Each Complexity Deserves a Pruning Policy. ArXiv, abs/2509.23931.
	[16] G. Hinton, O. Vinyals, and J. Dean, "Distilling the Knowledge in a Neural Network," in NIPS Deep Learning Workshop, 2015.
	[17] Y. Wang et al., "Self-Instruct: Aligning Language Models with Self-Generated Instructions," in Proc. Assoc. Comput. Linguist. (ACL), 2023, pp. 13484–13508.
	[18] K. Shridhar et al., "Distilling Reasoning Capabilities into Smaller Language Models," arXiv preprint arXiv:2305.18392, 2023.
	[19] E. Frantar et al., "GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers," in Proc. Int. Conf. Learn. Represent. (ICLR), 2023.
	[20] Lin, J., Tang, J., Tang, H., Yang, S., Dang, X., & Han, S. (2023). AWQ: Activation-aware Weight Quantization for On-Device LLM Compression and Acceleration. GetMobile: Mobile Computing and Communications, 28, 12 - 17.
	[21] T. Dettmers et al., "QLoRA: Efficient Finetuning of Quantized LLMs," in Proc. Adv. Neural Inf. Process. Syst. (NeurIPS), 2023.
	[22] T. Dao et al., "FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness," in Proc. Adv. Neural Inf. Process. Syst. (NeurIPS), 2022.
	[23] S. Mukherjee et al., "Orca: Progressive Learning from Complex Explanation Traces of GPT-4," arXiv preprint arXiv:2306.02707, 2023.
	[24] W. Kwon et al., "Efficient Memory Management for Large Language Model Serving with PagedAttention," in Proc. ACM Symp. Oper. Syst. Princ. (SOSP), 2023.
	[25] G. Gerganov, "llama.cpp," GitHub repository, 2023. [Online]. Available: https://github.com/ggerganov/llama.cpp (https://github.com/ggerganov/llama.cpp)
	[26] S. Liu et al., "AerialVLN: Vision-and-Language Navigation for UAVs," in Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 2023.

	[27] C.-Y. Hu et al., "See, Point, Fly: A Learning-Free VLM Framework for Universal Unmanned Aerial Navigation," arXiv preprint arXiv:2509.22653, 2025. [28] Zhang, W., Gao, C., Yu, S., Peng, R., Zhao, B., Zhang, Q., Cui, J., Chen, X., & Li, Y. (2025). CityNavAgent: Aerial Vision-and-Language Navigation with Hierarchical Semantic Planning and Global Memory. ArXiv, abs/2505.05622. [29] W. Jiang et al., "LongFly: Long-Horizon UAV Vision-and-Language Navigation with Spatiotemporal Context Integration," arXiv preprint arXiv:2512.22009, 2025. [30] Li, T., Huai, T., Li, Z., Gao, Y., Li, H., & Zheng, X. (2025). SkyVLN: Vision-and-Language Navigation and NMPC Control for UAVs in Urban Environments. 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 17199-17206.
指导教师意见 指导教师签字: 年 月 日	
专家组评审意见 专家组组长签字: 年 月 日	

填写说明:本报告书可打印,签名须手写,如表格容量不够,可根据内容增加页数,但不得随意删减项目.